






Outils bayésiens en traitement d'images

Jean-Baptiste Courbot

`jean-baptiste.courbot@uha.fr`



Contexte du traitement d'image :

- complexité
- nombre
- nouveauté

Problématiques :

- comment inférer ?
- comment modéliser ?
- comment faire sans exemple ?



Organisation :

- 4 séances de 3h45
- 3 rapports de TP à rendre au fil de l'eau pour une note finale
- 2/3 de la note du cours "outils avancés en traitement d'image"

Organisation :

- 4 séances de 3h45
- 3 rapports de TP à rendre au fil de l'eau pour une note finale
- 2/3 de la note du cours "outils avancés en traitement d'image"

Moyens :

- Moodle pour les ressources (slides, énoncés) et dépôt de travail.
- Google Colaboratory pour les notebooks Jupyter

I. Généralités

II. Le cas indépendant

III. Chaînes de Markov cachées

IV. Champs de Markov Cachés

V. Éléments de conclusion

Généralités

Nous travaillerons avec :

- des variables aléatoires A et leur réalisations a
- des vecteurs aléatoires \mathbf{A} de réalisation \mathbf{a}
- la notation « générale » $p(A = a)$ est abrégée en $p(a)$ lorsqu'il n'y a pas confusion
- des paramètres Θ qui interviennent dans une loi ; on les fait apparaître sous la forme de $p_{\Theta}(a)$

Pourquoi ?

On considère un couple (\mathbf{x}, \mathbf{y}) avec :

- \mathbf{y} un vecteur à valeurs dans \mathbb{R}
- \mathbf{x} un vecteur « caché »

\mathbf{y} est l'image observée et on souhaite estimer \mathbf{x} qui peut prendre :

- des valeurs discrètes : on parle de **segmentation** d'images
- des valeurs réelles : **restauration** d'images

Pour estimer \mathbf{x} à partir de \mathbf{y} il faut **modéliser** le problème.

Lien déterministe : $\mathbf{x} = f(\mathbf{y})$ i.e. f tient compte de tous les paramètres

Lien probabiliste :

- \mathbf{y} est la réalisation **observable** d'une v.a. \mathbf{Y}
- \mathbf{x} est la réalisation **invisible** d'une v.a. \mathbf{X}

Il faut donc modéliser $p(\mathbf{X} = \mathbf{x} | \mathbf{Y} = \mathbf{y})$!

Le cadre bayésien (II)

La loi de Bayes nous permet d'écrire :

$$p(\mathbf{x}|\mathbf{y}) = \frac{p(\mathbf{x}, \mathbf{y})}{p(\mathbf{y})} = \frac{p(\mathbf{y}|\mathbf{x})p(\mathbf{x})}{p(\mathbf{y})}$$

Comme $p(\mathbf{y})$ est constante (l'image est connue, fixée) on note souvent

$$p(\mathbf{x}|\mathbf{y}) \propto p(\mathbf{y}|\mathbf{x})p(\mathbf{x})$$

Le cadre bayésien (II)

La loi de Bayes nous permet d'écrire :

$$p(\mathbf{x}|\mathbf{y}) = \frac{p(\mathbf{x}, \mathbf{y})}{p(\mathbf{y})} = \frac{p(\mathbf{y}|\mathbf{x})p(\mathbf{x})}{p(\mathbf{y})}$$

Comme $p(\mathbf{y})$ est constante (l'image est connue, fixée) on note souvent

$$p(\mathbf{x}|\mathbf{y}) \propto p(\mathbf{y}|\mathbf{x})p(\mathbf{x})$$

Tous ces termes portent un nom :

- $p(\mathbf{x}|\mathbf{y})$ est la probabilité a posteriori
- $p(\mathbf{x})$ est la probabilité a priori
- $p(\mathbf{y}|\mathbf{x})$ est la densité conditionnelle de \mathbf{Y} sachant $\mathbf{X} = \mathbf{x}$ → la vraisemblance
- $p(\mathbf{x}, \mathbf{y})$ est la densité du couple = la loi jointe

On dispose de données $\mathbf{Y} = \mathbf{y}$; et on veut déduire une segmentation $\mathbf{X} = \mathbf{x}$.

1. Établir le **modèle a priori** pour \mathbf{X} : quelle est sa structure ?

On dispose de données $\mathbf{Y} = \mathbf{y}$; et on veut déduire une segmentation $\mathbf{X} = \mathbf{x}$.

1. Établir le **modèle a priori** pour \mathbf{X} : quelle est sa structure ?
2. Établir un **modèle d'observation** pour lier \mathbf{Y} à \mathbf{X} .

On dispose de données $\mathbf{Y} = \mathbf{y}$; et on veut déduire une segmentation $\mathbf{X} = \mathbf{x}$.

1. Établir le **modèle a priori** pour \mathbf{X} : quelle est sa structure ?
2. Établir un **modèle d'observation** pour lier \mathbf{Y} à \mathbf{X} .
3. Les paramètres du modèle sont-ils connus ?
 - si oui : on les note Θ
 - sinon : il faudra estimer un $\hat{\Theta}$

On dispose de données $\mathbf{Y} = \mathbf{y}$; et on veut déduire une segmentation $\mathbf{X} = \mathbf{x}$.

1. Établir le **modèle a priori** pour \mathbf{X} : quelle est sa structure ?
2. Établir un **modèle d'observation** pour lier \mathbf{Y} à \mathbf{X} .
3. Les paramètres du modèle sont-ils connus ?
 - si oui : on les note Θ
 - sinon : il faudra estimer un $\hat{\Theta}$
4. Estimer $\mathbf{X} = \mathbf{x}$ à l'aide de $p_{\Theta}(\mathbf{X}|\mathbf{Y})$ ou $p_{\hat{\Theta}}(\mathbf{X}|\mathbf{Y})$.

Problématique principale : **segmentation d'image**.

Nous allons étudier trois modèles *a priori* :

- sites (pixels) IID
- chaîne de Markov
- champs de Markov

... dans un contexte :

- supervisé : Θ connu
- non supervisé : Θ inconnu

Le cas indépendant

Le cas indépendant

Cadre

Le modèle le plus simple : tous les pixels sont indépendants.

Donc sur une image $\mathbf{x} = \{x_s\}_{s \in \mathcal{S}}$:

▷ \mathcal{S} = ensemble des pixels (sites)

$$p(\mathbf{X} = \mathbf{x}) = \prod_{s \in \mathcal{S}} p(X_s = x_s)$$

Le modèle le plus simple : tous les pixels sont indépendants.

Donc sur une image $\mathbf{x} = \{x_s\}_{s \in \mathcal{S}}$:

▷ \mathcal{S} = ensemble des pixels (sites)

$$p(\mathbf{X} = \mathbf{x}) = \prod_{s \in \mathcal{S}} p(X_s = x_s)$$

Les classes sont discrètes : $\mathbf{x}_s \in \Omega \stackrel{\text{def.}}{=} \{\omega_1, \omega_2, \dots, \omega_K\}$

Les lois a priori sont basées sur $p(X_s = \omega_k) \stackrel{\text{def.}}{=} \pi_k$.

$$\triangleright \sum_k \pi_k = 1$$

Modèle d'observation

On se donne une loi qui lie \mathbf{Y} et \mathbf{X} .

Hypothèse du bruit indépendant : (Conservée sur le cours)

$$p(\mathbf{Y} = \mathbf{y} | \mathbf{X} = \mathbf{x}) = \prod_{s \in \mathcal{S}} p(Y_s = y_s | X_s = x_s)$$

Modèle d'observation

On se donne une loi qui lie \mathbf{Y} et \mathbf{X} .

Hypothèse du bruit indépendant : (Conservée sur le cours)

$$p(\mathbf{Y} = \mathbf{y} | \mathbf{X} = \mathbf{x}) = \prod_{s \in \mathcal{S}} p(Y_s = y_s | X_s = x_s)$$

On suppose $\mathbf{y}_s \in \mathbb{R}$. Souvent (et pour ce cours) on utilise la loi normale :

$$\forall s, p(Y_s = y_s | X_s = x_s) \sim \mathcal{N}(\mu(x_s), \sigma(x_s))$$

En faisant le lien avec Ω on note plutôt :

$$\forall s, p(Y_s = y_s | X_s = \omega_k) \sim \mathcal{N}(\mu_k, \sigma_k)$$

Finalement :

$$\begin{aligned} p(\mathbf{x}|\mathbf{y}) &\propto p(\mathbf{y}|\mathbf{x})p(\mathbf{x}) \\ &= \prod_{s \in \mathcal{S}} p(Y_s = y_s | X_s = x_s) \prod_{s \in \mathcal{S}} p(X_s = x_s) \\ &= \prod_{s \in \mathcal{S}} p(Y_s = y_s | X_s = \omega_k) p(X_s = \omega_k) \\ &= \prod_{s \in \mathcal{S}} \mathcal{N}(y_s; \mu_k, \sigma_k) p(X_s = \omega_k) \end{aligned}$$

Finalement :

$$\begin{aligned} p(\mathbf{x}|\mathbf{y}) &\propto p(\mathbf{y}|\mathbf{x})p(\mathbf{x}) \\ &= \prod_{s \in \mathcal{S}} p(Y_s = y_s | X_s = x_s) \prod_{s \in \mathcal{S}} p(X_s = x_s) \\ &= \prod_{s \in \mathcal{S}} p(Y_s = y_s | X_s = \omega_k) p(X_s = \omega_k) \\ &= \prod_{s \in \mathcal{S}} \mathcal{N}(y_s; \mu_k, \sigma_k) p(X_s = \omega_k) \end{aligned}$$



Paramètres du modèle :

$$\Theta = \{\pi_1, \dots, \pi_k, \mu_1, \dots, \mu_k, \sigma_1, \dots, \sigma_k\}$$

Θ est supposé connu pour l'instant.



Simulation

1. Simuler $\mathbf{X} = \mathbf{x}$ à l'aide des π_k : on fait un tirage aléatoire en chaque site s
2. Simuler $\mathbf{Y} = \mathbf{y}$ conditionnellement à $\mathbf{X} = \mathbf{x}$: idem.



Simulation

1. Simuler $\mathbf{X} = \mathbf{x}$ à l'aide des π_k : on fait un tirage aléatoire en chaque site s
2. Simuler $\mathbf{Y} = \mathbf{y}$ conditionnellement à $\mathbf{X} = \mathbf{x}$: idem.



Le cas indépendant

Segmentation

Objectif : estimer $\mathbf{X} = \mathbf{x}$ à partir de $\mathbf{Y} = \mathbf{y}$.

Pour cela il faut :

- connaître la loi à posteriori $p(\mathbf{X} = \mathbf{x} | \mathbf{Y} = \mathbf{y})$ (vu à l'instant)
- connaître les paramètres Θ (supposés connus pour l'instant)
- établir une fonction de perte de décision

Une **stratégie** $\hat{\eta} : \mathbb{R}^S \rightarrow \Omega^S$ associe à une observation \mathbf{y} une estimée \mathbf{x} .

◁ $S = |\mathcal{S}|$ le nombre de sites

- $\hat{\eta}$ est déterministe
- $\hat{\eta}$ peut se tromper

Stratégie bayésienne, fonctions de perte

Une **stratégie** $\hat{\eta} : \mathbb{R}^S \rightarrow \Omega^S$ associe à une observation \mathbf{y} une estimée \mathbf{x} .

◁ $S = |\mathcal{S}|$ le nombre de sites

- $\hat{\eta}$ est déterministe
- $\hat{\eta}$ peut se tromper

Une **fonction de perte** donne un coût aux erreurs commises :

$$L(\omega_i, \omega_j) = \begin{cases} 0 & \text{si } \omega_i = \omega_j \\ \lambda_{ij} & \text{sinon} \end{cases}$$

On peut définir une perte moyenne (ou risque moyen) comme $\mathbb{E}[L(\hat{\eta}(Y), X)]$

La **stratégie bayésienne** $\hat{\eta}_{\text{Bayes}}$ est celle qui minimise le risque moyen :

$$\mathbb{E} [L(\hat{\eta}_{\text{Bayes}}(Y), X)] = \min_{\hat{\eta}} \mathbb{E} [L(\hat{\eta}(Y), X)]$$

Stratégie bayésienne, fonctions de perte (II)

La **stratégie bayésienne** $\hat{\eta}_{\text{Bayes}}$ est celle qui minimise le risque moyen :

$$\mathbb{E} [L(\hat{\eta}_{\text{Bayes}}(Y), X)] = \min_{\hat{\eta}} \mathbb{E} [L(\hat{\eta}(Y), X)]$$

On peut montrer que $\hat{\eta}_{\text{Bayes}}$ est définie par :

$$\hat{\eta}_{\text{Bayes}}(y) = \omega_{\textcolor{brown}{m}} \Leftrightarrow \sum_{i=1}^k \lambda_{\textcolor{brown}{m},i} p(x = \omega_i | y) \leq \sum_{i=1}^k \lambda_{\textcolor{green}{j},i} p(x = \omega_i | y) \forall \textcolor{green}{j} \in \{1, \dots, k\}$$

Interprétation : on minimise le coût pondéré par la probabilité a posteriori.

Deux fonctions de pertes sont très répandues. Soient deux images \mathbf{x}^1 et \mathbf{x}^2 :

- La fonction de perte 0-1 sur toute l'image :

$$L(\mathbf{x}^1, \mathbf{x}^2) = \begin{cases} 0 & \text{si } \mathbf{x}^1 = \mathbf{x}^2 \\ 1 & \text{sinon} \end{cases}$$

Deux fonctions de pertes sont très répandues. Soient deux images \mathbf{x}^1 et \mathbf{x}^2 :

- La fonction de perte 0-1 sur toute l'image :

$$L(\mathbf{x}^1, \mathbf{x}^2) = \begin{cases} 0 & \text{si } \mathbf{x}^1 = \mathbf{x}^2 \\ 1 & \text{sinon} \end{cases}$$

- La fonction de perte 0-1 sur chaque pixel avec somme des erreurs :

$$L(\mathbf{x}^1, \mathbf{x}^2) = \sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s^1 \neq x_s^2\}}$$

Stratégie bayésienne, fonctions de perte (IV)

Ces deux fonctions se traduisent par deux critères bayésiens classiques :

Le **maximum a posteriori** (MAP) :

$$\hat{\mathbf{x}}^{\text{MAP}} = \arg \max_{\mathbf{x} \in \Omega^S} p(\mathbf{X} = \mathbf{x} | \mathbf{Y} = \mathbf{y})$$

Stratégie bayésienne, fonctions de perte (IV)

Ces deux fonctions se traduisent par deux critères bayésiens classiques :

Le **maximum a posteriori** (MAP) :

$$\hat{\mathbf{x}}^{\text{MAP}} = \arg \max_{\mathbf{x} \in \Omega^S} p(\mathbf{X} = \mathbf{x} | \mathbf{Y} = \mathbf{y})$$

Le **maximum posterior mode** (MPM), où $\forall s \in \mathcal{S}$:

$$\hat{x}_s^{\text{MPM}} = \arg \max_{x_s \in \Omega} p(X_s = x_s | \mathbf{Y} = \mathbf{y})$$

Dans le modèle indépendant, on montre facilement que $\hat{\mathbf{x}}^{\text{MAP}} = \hat{\mathbf{x}}^{\text{MPM}}$.

En effet, $p(\mathbf{x} | \mathbf{y}) = \prod_{s \in \mathcal{S}} p(x_s | y_s)$.

Pour résumer, segmenter (MAP ou MPM) dans le modèle indépendant c'est :

- calculer $p(X_s = \omega_k | y_s)$ pour tout site s et classe k
- pour tout site s : choisir la classe la plus probable.

Remarque : on a supposé Θ connu !

Le cas indépendant

Segmentation non supervisée

Contexte. On ne connaît pas toujours les paramètres Θ .

Objectif : estimer conjointement \mathbf{x} et Θ à partir de $\mathbf{Y} = \mathbf{y}$ uniquement.

Optimisation alternée avec les algorithmes SEM et EM :

- estimer $\hat{\mathbf{x}}$ à partir de $\mathbf{y}, \hat{\Theta}$
- estimer $\hat{\Theta}$ à partir de $\hat{\mathbf{x}}, \mathbf{y}$

◁ vu précédemment

... et répéter jusqu'à convergence.

Estimer $\hat{\Theta}$ à partir de (\mathbf{x}, \mathbf{y}) : estimateurs du max. de vraisemblance (EMV)

Avec les données complètes (\mathbf{x}, \mathbf{y}) , et pour toutes les classes $\omega_k \in \Omega$, on peut estimer :

- la proportion :

$$\hat{\pi}_k = \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}}$$

Estimer $\hat{\Theta}$ à partir de (\mathbf{x}, \mathbf{y}) : estimateurs du max. de vraisemblance (EMV)

Avec les données complètes (\mathbf{x}, \mathbf{y}) , et pour toutes les classes $\omega_k \in \Omega$, on peut estimer :

- la proportion :

$$\hat{\pi}_k = \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}}$$

- la moyenne :

$$\hat{m}_k = \frac{\sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}} y_s}{\sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}}}$$

Estimer $\hat{\Theta}$ à partir de (\mathbf{x}, \mathbf{y}) : estimateurs du max. de vraisemblance (EMV)

Avec les données complètes (\mathbf{x}, \mathbf{y}) , et pour toutes les classes $\omega_k \in \Omega$, on peut estimer :

- la proportion :

$$\hat{\pi}_k = \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}}$$

- la moyenne :

$$\hat{m}_k = \frac{\sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}} y_s}{\sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}}}$$

- la variance :

$$\hat{\sigma}_k^2 = \frac{\sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}} (y_s - \hat{m}_k)^2}{\sum_{s \in \mathcal{S}} \mathbb{1}_{\{x_s = \omega_k\}}}$$

Algorithme **Stochastic Expectation-Maximization** (SEM) :

- On se donne une estimation initiale $\hat{\mathbf{x}}^{(0)}$.
- On répète ensuite à chaque itération q :
 - Estimer $\hat{\Theta}^{(q)}$ avec $(\mathbf{x}^{(q-1)}, \mathbf{y})$
 - Simuler $\mathbf{x}^{(q)}$ avec $(\hat{\Theta}^{(q)}, \mathbf{y})$ i.e. avec $p_{\hat{\Theta}^{(q)}}(\mathbf{x}|\mathbf{y})$
- Jusqu'à observer une « stabilité » des $\hat{\Theta}^{(q)}$.

Algorithme **Stochastic Expectation-Maximization** (SEM) :

- On se donne une estimation initiale $\hat{\mathbf{x}}^{(0)}$.
- On répète ensuite à chaque itération q :
 - Estimer $\hat{\Theta}^{(q)}$ avec $(\mathbf{x}^{(q-1)}, \mathbf{y})$
 - Simuler $\mathbf{x}^{(q)}$ avec $(\hat{\Theta}^{(q)}, \mathbf{y})$ i.e. avec $p_{\hat{\Theta}^{(q)}}(\mathbf{x}|\mathbf{y})$
- Jusqu'à observer une « stabilité » des $\hat{\Theta}^{(q)}$.

→ Intérêt : simple avec les outils déjà vus

→ Inconvénient : stochastique

Pour éviter l'aspect stochastique : revenir à l'objectif = estimer Θ .

Avec \mathbf{x} connu, les EMV résolvent :

$$\hat{\Theta} = \arg \max_{\Theta} p_{\Theta}(\mathbf{x}|\mathbf{y})$$

Pour éviter l'aspect stochastique : revenir à l'objectif = estimer Θ .

Avec \mathbf{x} connu, les EMV résolvent :

$$\hat{\Theta} = \arg \max_{\Theta} p_{\Theta}(\mathbf{x}|\mathbf{y})$$

À partir d'un Θ^t connu : calcul de **l'espérance conditionnelle** de la vraisemblance de Θ , étant donné $p_{\Theta^t}(\mathbf{x}|\mathbf{y})$.

$$Q(\Theta|\Theta^t) = \mathbb{E}_{\mathbf{x}|\mathbf{y},\Theta^t} [p_{\Theta}(\mathbf{x}|\mathbf{y})]$$

Algorithme EM (II)

On alterne à une itération t :

- Calcul de l'espérance conditionnelle $Q(\Theta|\Theta^t)$
- Choix de $\Theta^{t+1} = \arg \max_{\Theta} Q(\Theta|\Theta^t)$

◁ Expectation

◁ Maximisation

Algorithme EM (II)

On alterne à une itération t :

- Calcul de l'espérance conditionnelle $Q(\Theta|\Theta^t)$ ◁ Expectation
- Choix de $\Theta^{t+1} = \arg \max_{\Theta} Q(\Theta|\Theta^t)$ ◁ Maximisation

Dans le cas indépendant :

- Calcul de tous les $p(x_s = \omega_k | y_s, \Theta^t)$, pour tout s et k
- Estimation de Θ^{t+1} par les **estimateurs empiriques pondérés**

Algorithme EM (III)

Estimation de $\Theta^{(t+1)}$ par les estimateurs empiriques pondérés avec $p(x_s = \omega_k | y_s, \Theta^t)$ et \mathbf{y} .

$$\hat{\pi}_k^{(t+1)} = \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t)$$

Algorithme EM (III)

Estimation de $\Theta^{(t+1)}$ par les estimateurs empiriques pondérés avec $p(x_s = \omega_k | y_s, \Theta^t)$ et \mathbf{y} .

$$\hat{\pi}_k^{(t+1)} = \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t)$$
$$\hat{m}_k^{(t+1)} = \frac{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t) y_s}{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t)}$$

Algorithme EM (III)

Estimation de $\Theta^{(t+1)}$ par les estimateurs empiriques pondérés avec $p(x_s = \omega_k | y_s, \Theta^t)$ et \mathbf{y} .

$$\begin{aligned}\hat{\pi}_k^{(t+1)} &= \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t) \\ \hat{m}_k^{(t+1)} &= \frac{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t) y_s}{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t)} \\ (\hat{\sigma}_k^2)^{(t+1)} &= \frac{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t) (y_s - \hat{m}_k^{(t+1)})^2}{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t)}\end{aligned}$$

Algorithme EM (III)

Estimation de $\Theta^{(t+1)}$ par les estimateurs empiriques pondérés avec $p(x_s = \omega_k | y_s, \Theta^t)$ et \mathbf{y} .

$$\begin{aligned}\hat{\pi}_k^{(t+1)} &= \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t) \\ \hat{m}_k^{(t+1)} &= \frac{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t) y_s}{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t)} \\ (\hat{\sigma}_k^2)^{(t+1)} &= \frac{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t) (y_s - \hat{m}_k^{(t+1)})^2}{\sum_{s \in \mathcal{S}} p(x_s = \omega_k | y_s, \Theta^t)}\end{aligned}$$

Remarque : similarité avec les EMV ; en remplaçant $\mathbb{1}_{\{x_s = \omega_k\}}$ par $p(x_s = \omega_k | y_s, \Theta^t)$.

Nous avons vu :

- les hypothèses du modèle indépendant et la loi jointe
- les fonctions de pertes et les critères du MAP, du MPM
 - ▷ généralisables
- l'estimation des paramètres dans le cas indépendant
 - ▷ réutilisables
- EM et SEM
 - ▷ généralisables